

## 卷积神经网络 (3)



深度学习

# 概览

---

1. 卷积核的来源。
2. 卷积神经网络中的参数。
3. 卷积神经网络的反向传播算法。
  1. 池化层的前一层的残差。
  2. 卷积层的前一层的残差。
  3. 卷积核参数的梯度。
4. 了解卷积神经网络中的经典模型。

# 1. 卷积核的来源

# 卷积核来源

---

## 1. 根据实践经验、统计学规律进行人工设定。


例如Sobel算子， Prewitt算子等。



# 卷积核来源

---


2. 通过训练得到：反向传播算法。



# 卷积核的来源

---

思考：两种卷积核（或算子）来源的优缺点？




## 2. 卷积神经网络 中的参数

## 2.1 卷积中的参数




# 卷积的参数是什么


---



图




卷积核




生成特征图

卷积核是需要求解的参数。


# 卷积运算



图



卷积核



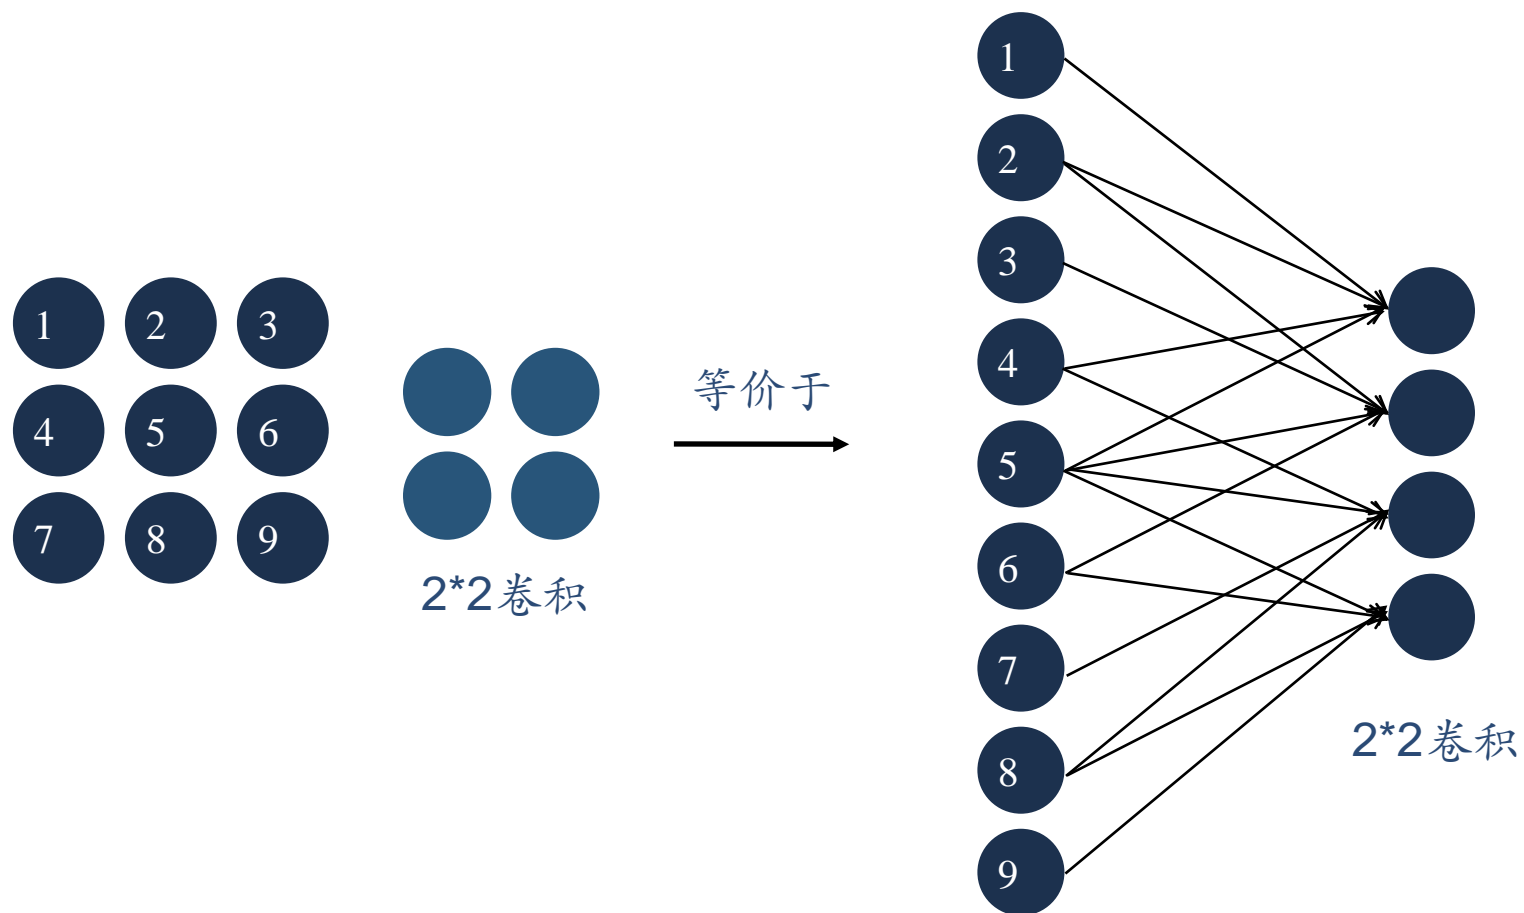
生成特征图

$$z_{u,v}^{(l+1)} = \sum_p \sum_q w_{p,q}^{(l+1)} a_{u+p-1,v+q-1}^{(l)} + b^{(l+1)}$$

$$a_{u,v}^{(l+1)} = \sigma(z_{u,v}^{(l+1)})$$


## 2.2 卷积与全连接 的关系

# 卷积展开




# 全连接与局部连接对比

---



全连接




$2 \times 2$ 卷积

# 全连接与卷积的参数对比

全连接

连接数量: 36

参数数量: 36




2\*2 卷积

(局部连接, 权值共享)

连接数量: 16

参数数量: 4



→  $w_{11}$   
→  $w_{12}$   
→  $w_{21}$   
→  $w_{22}$

### 3. CNN的反向传播算法

# CNN反向传播算法

---


与全连接神经网络相比

1. 池化层的前一层残差计算。
2. 卷积层的前一层残差计算。
3. 卷积核中的参数的偏导数计算。




## 3.1 池化层的前一层残差

# 池化层前向传播



为了方便，此处使用步长等于滑窗大小的池化方法。且不考虑池化层激活函数。

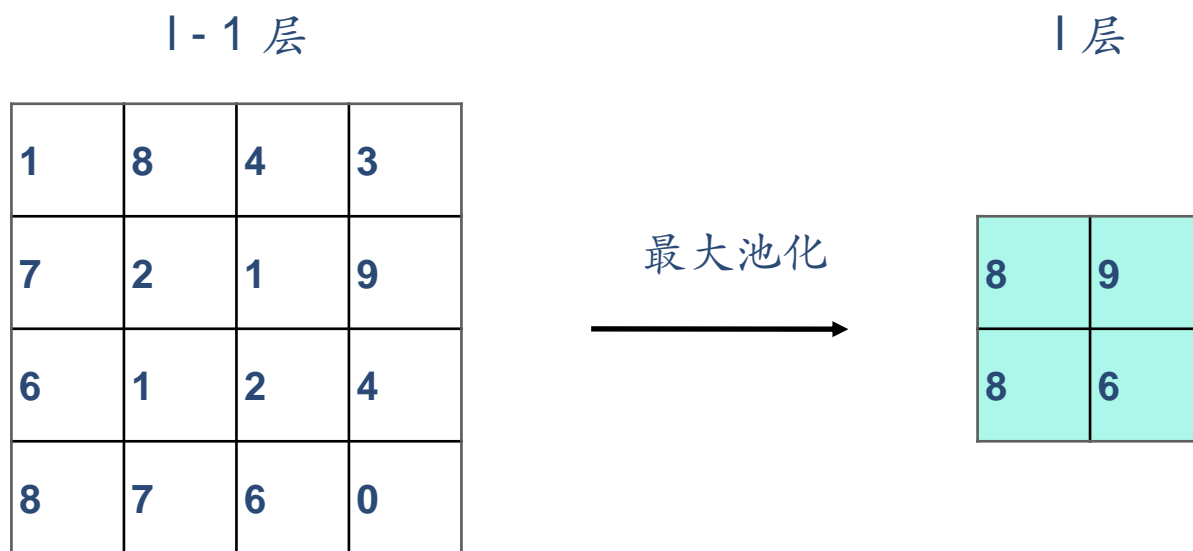
# 池化层的前一层的残差



一般的，池化层没有参数需要学习，仅需要将残差传递给前一层即可。


最大池化层的前  
一层残差

# 最大池化层的前向传播



$$a_{p,q}^{(l)} = z_{p,q}^{(l)} = \max(a_{(p-1)*m+1,(q-1)*n+1}^{(l-1)}, \dots, a_{p*m,q*n}^{(l-1)})$$
 此处的m、n指步长。

# 最大池化层的前一层残差



# 最大池化层的前一层残差

---

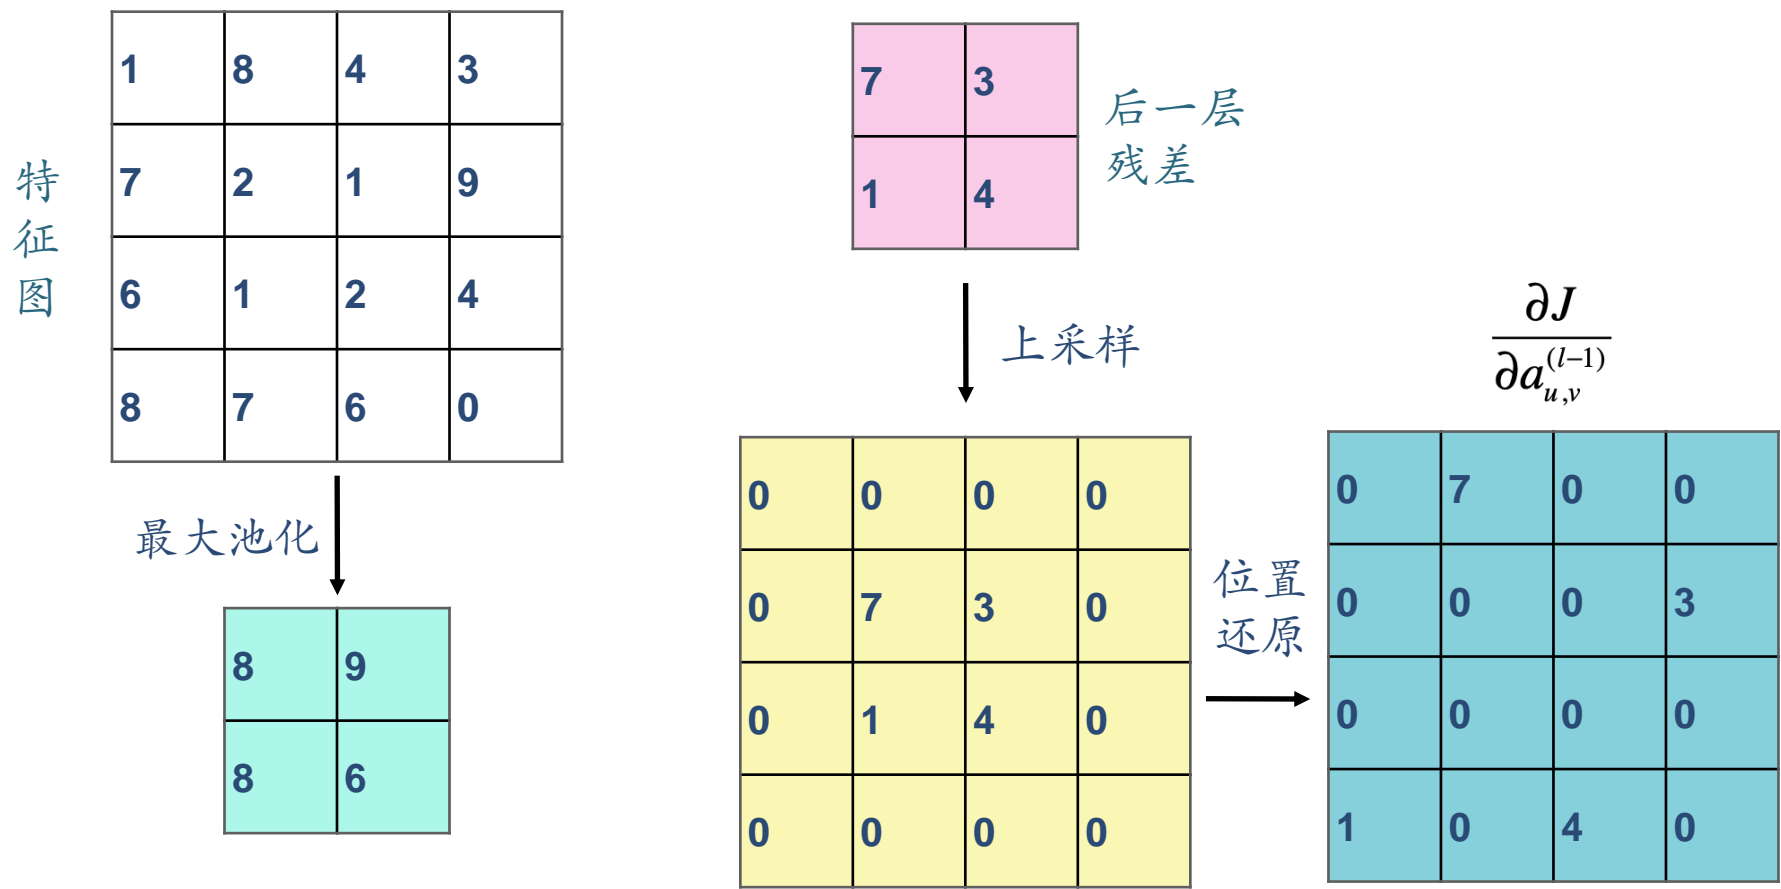
$$\delta_{u,v}^{(l-1)} = \frac{\partial J}{\partial a_{u,v}^{(l-1)}} \frac{\partial a_{u,v}^{(l-1)}}{\partial z_{u,v}^{(l-1)}} = \frac{\partial J}{\partial z_{p,q}^{(l)}} \frac{\partial z_{p,q}^{(l)}}{\partial a_{u,v}^{(l-1)}} \frac{\partial a_{u,v}^{(l-1)}}{\partial z_{u,v}^{(l-1)}} = \delta_{p,q}^{(l)} \frac{\partial z_{p,q}^{(l)}}{\partial a_{u,v}^{(l-1)}} \sigma'(z_{u,v}^{(l-1)})$$

$$\text{当 } \frac{\partial z_{p,q}^{(l)}}{\partial a_{u,v}^{(l-1)}} = 0 \quad \text{则 } \delta_{u,v}^{(l-1)} = 0$$

$$\text{当 } \frac{\partial z_{p,q}^{(l)}}{\partial a_{u,v}^{(l-1)}} = 1 \quad \text{则 } \delta_{u,v}^{(l-1)} = \delta_{p,q}^{(l)} \sigma'(z_{u,v}^{(l-1)})$$

$$\delta_{u,v}^{(l-1)} = \text{upsample}(\delta_{p,q}^{(l)}) \sigma'(z_{u,v}^{(l-1)})$$

# 最大池化层前向与反向传播




前向传播

反向传播



**平均池化层的前一  
层残差**


# 平均池化层的前向传播



$$a_{p,q}^{(l)} = z_{p,q}^{(l)} = \text{avg}(\text{sum}(a_{(p-1)*m+1, (q-1)*n+1}^{(l-1)}, \dots, a_{p*m, q*n}^{(l-1)}))$$

此处的m、n指步长。

# 平均池化层的前一层残差



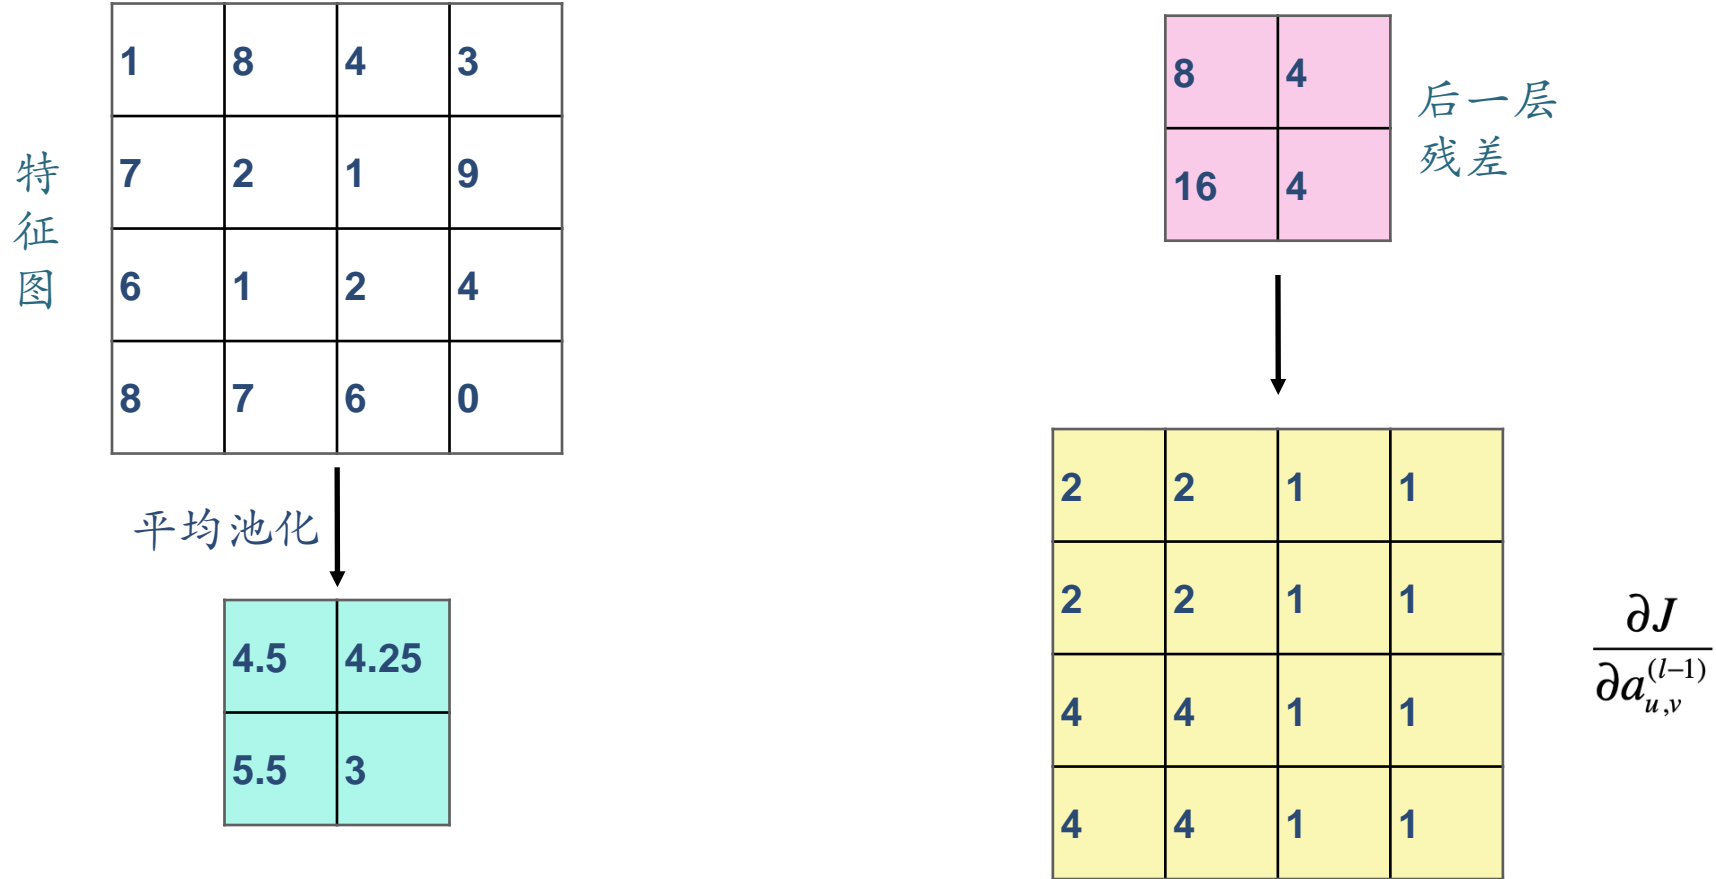
# 平均池化层的前一层残差

---

$$\delta_{u,v}^{(l-1)} = \frac{\partial J}{\partial a_{u,v}^{(l-1)}} \frac{\partial a_{u,v}^{(l-1)}}{\partial z_{u,v}^{(l-1)}} = \frac{\partial J}{\partial z_{p,q}^{(l)}} \frac{\partial z_{p,q}^{(l)}}{\partial a_{u,v}^{(l-1)}} \frac{\partial a_{u,v}^{(l-1)}}{\partial z_{u,v}^{(l-1)}} = \frac{1}{m * n} \delta_{p,q}^{(l)} \sigma'(z_{u,v}^{(l-1)})$$

其中m、n分别表示滑窗的高、宽。

# 平均池化层的前向与反向传播



前向传播

前向传播

## 3.2 卷积层的前一层残差

# 全连接ANN反向传播算法


---

全连接神经网络隐藏层的残差：

$$\delta_j^{(l)} = (w_j^{(l+1)})^T \cdot \delta^{(l+1)} \cdot \sigma'(z_j^{(l)})$$

即  $\delta_j^{(l)} \sim (w_j^{(l+1)})^T \cdot \delta^{(l+1)}$



# 全连接ANN反向传播算法



$$\delta_1^{(2)} \sim w_{11}^{(3)} \cdot \delta_1^{(3)} + w_{21}^{(3)} \cdot \delta_2^{(3)} + w_{31}^{(3)} \cdot \delta_3^{(3)}$$




# 全连接与卷积层的连接关系




结合全连接层的残差  
求取公式，猜想卷积  
前一层的残差？

# 卷积的前一层的残差



卷积在正向传播时，卷积参数与输入运算，输出的是特征图。反向传播时，卷积参数与卷积层残差运算，输出的是前一层的残差。

# 卷积的前向传播



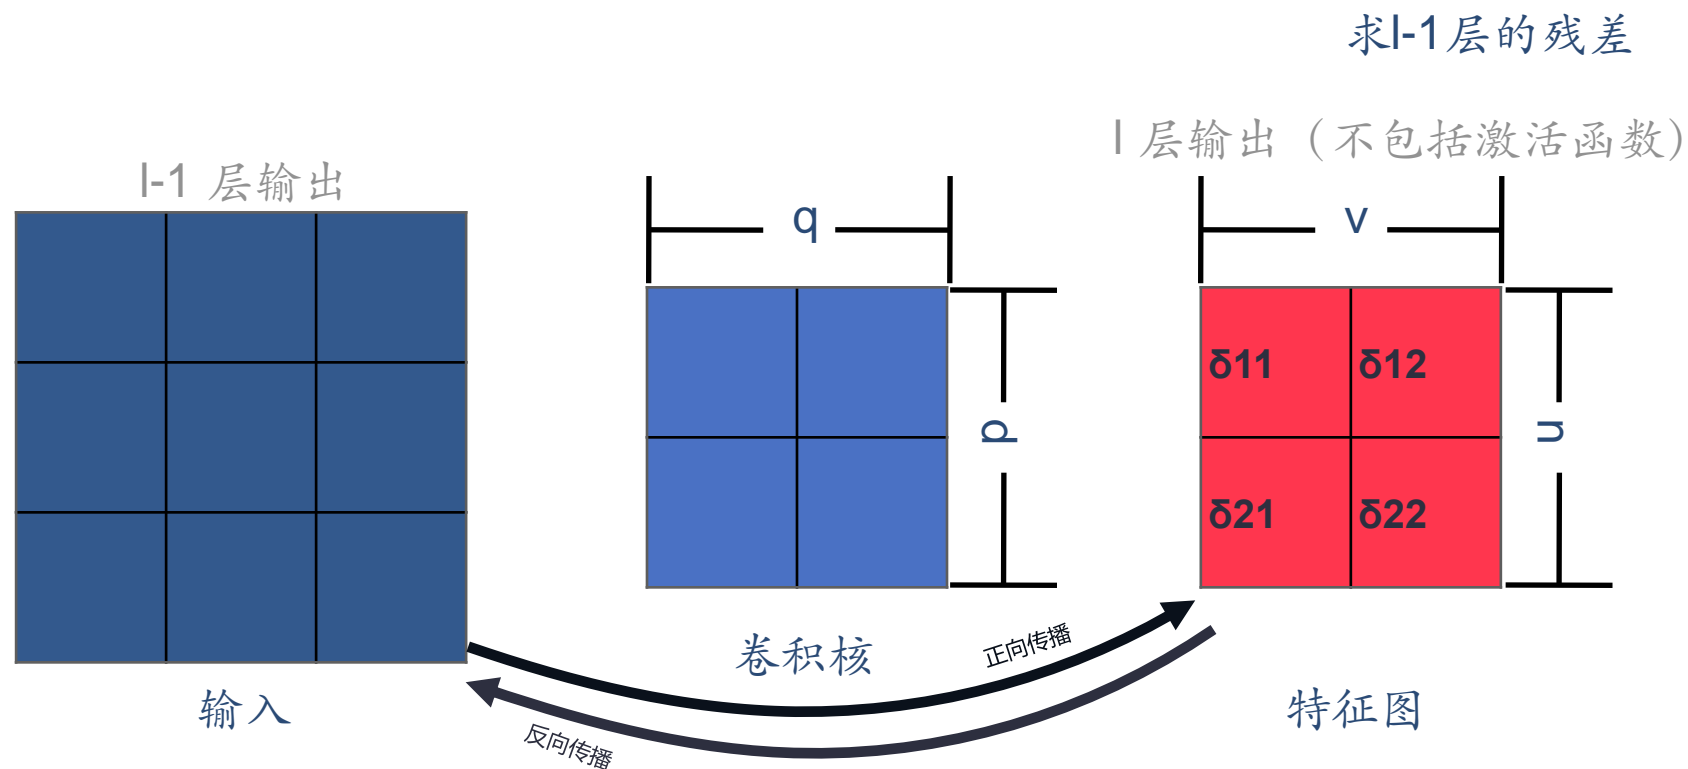
$$z_{p,q}^{(l)} = \sum_m \sum_n w_{m,n}^{(l)} a_{p+m-1,q+n-1}^{(l-1)} + b^{(l)} \quad a_{p,q}^{(l)} = \sigma(z_{p,q}^{(l)})$$

为了计算方便，默认情况下步长为1，卷积核数量为1。



# 卷积层前一层残 差——实例

# 实例：前向传播



卷积层输入和

$$\begin{aligned} z_{11}^{(l)} &= a_{11}^{(l-1)} w_{11}^{(l)} + a_{12}^{(l-1)} w_{12}^{(l)} + a_{21}^{(l-1)} w_{21}^{(l)} + a_{22}^{(l-1)} w_{22}^{(l)} + b^{(l)} \\ z_{12}^{(l)} &= a_{12}^{(l-1)} w_{11}^{(l)} + a_{13}^{(l-1)} w_{12}^{(l)} + a_{22}^{(l-1)} w_{21}^{(l)} + a_{23}^{(l-1)} w_{22}^{(l)} + b^{(l)} \\ z_{21}^{(l)} &= a_{21}^{(l-1)} w_{11}^{(l)} + a_{22}^{(l-1)} w_{12}^{(l)} + a_{31}^{(l-1)} w_{21}^{(l)} + a_{32}^{(l-1)} w_{22}^{(l)} + b^{(l)} \\ z_{22}^{(l)} &= a_{22}^{(l-1)} w_{11}^{(l)} + a_{23}^{(l-1)} w_{12}^{(l)} + a_{32}^{(l-1)} w_{21}^{(l)} + a_{33}^{(l-1)} w_{22}^{(l)} + b^{(l)} \end{aligned}$$

# 实例：残差

---

$$z_{11}^{(l)} = \boxed{a_{11}^{(l-1)} w_{11}^{(l)}} + a_{12}^{(l-1)} w_{12}^{(l)} + a_{21}^{(l-1)} w_{21}^{(l)} + a_{22}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{12}^{(l)} = a_{12}^{(l-1)} w_{11}^{(l)} + a_{13}^{(l-1)} w_{12}^{(l)} + a_{22}^{(l-1)} w_{21}^{(l)} + a_{23}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{21}^{(l)} = a_{21}^{(l-1)} w_{11}^{(l)} + a_{22}^{(l-1)} w_{12}^{(l)} + a_{31}^{(l-1)} w_{21}^{(l)} + a_{32}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{22}^{(l)} = a_{22}^{(l-1)} w_{11}^{(l)} + a_{23}^{(l-1)} w_{12}^{(l)} + a_{32}^{(l-1)} w_{21}^{(l)} + a_{33}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$\delta_{11}^{(l-1)}$  残差仅仅与 $z_{11}$ 输入有关  $\frac{\partial z_{11}^{(l)}}{\partial a_{11}^{(l-1)}} = \frac{\partial(a_{11}^{(l-1)} w_{11}^{(l)})}{\partial a_{11}^{(l-1)}} = w_{11}^{(l)}$

$$\delta_{11}^{(l-1)} = \frac{\partial J}{\partial z_{11}^{(l-1)}} = \frac{\partial J}{\partial z_{11}^{(l)}} \frac{\partial z_{11}^{(l)}}{\partial a_{11}^{(l-1)}} \frac{\partial a_{11}^{(l-1)}}{\partial z_{11}^{(l-1)}} = \delta_{11}^{(l)} w_{11}^{(l)} \sigma'(z_{11}^{(l-1)})$$

# 实例：残差

$$\begin{aligned}z_{11}^{(l)} &= a_{11}^{(l-1)}w_{11}^{(l)} + \boxed{a_{12}^{(l-1)}w_{12}^{(l)}} + a_{21}^{(l-1)}w_{21}^{(l)} + a_{22}^{(l-1)}w_{22}^{(l)} + b^{(l)} \\z_{12}^{(l)} &= \boxed{a_{12}^{(l-1)}w_{11}^{(l)}} + a_{13}^{(l-1)}w_{12}^{(l)} + a_{22}^{(l-1)}w_{21}^{(l)} + a_{23}^{(l-1)}w_{22}^{(l)} + b^{(l)} \\z_{21}^{(l)} &= a_{21}^{(l-1)}w_{11}^{(l)} + a_{22}^{(l-1)}w_{12}^{(l)} + a_{31}^{(l-1)}w_{21}^{(l)} + a_{32}^{(l-1)}w_{22}^{(l)} + b^{(l)} \\z_{22}^{(l)} &= a_{22}^{(l-1)}w_{11}^{(l)} + a_{23}^{(l-1)}w_{12}^{(l)} + a_{32}^{(l-1)}w_{21}^{(l)} + a_{33}^{(l-1)}w_{22}^{(l)} + b^{(l)}\end{aligned}$$

$\delta_{12}^{(l-1)}$

残差与 $z_{11}$ 、 $z_{12}$ 输入有关

$$\begin{aligned}\frac{\partial z_{11}^{(l)}}{\partial a_{12}^{(l-1)}} &= \frac{\partial(a_{12}^{(l-1)}w_{12}^{(l)})}{\partial a_{12}^{(l-1)}} = w_{12}^{(l)} \\ \frac{\partial z_{12}^{(l)}}{\partial a_{12}^{(l-1)}} &= \frac{\partial(a_{12}^{(l-1)}w_{11}^{(l)})}{\partial a_{12}^{(l-1)}} = w_{11}^{(l)}\end{aligned}$$

$$\delta_{12}^{(l-1)} = \frac{\partial J}{\partial z_{12}^{(l-1)}} = \frac{\partial J}{\partial z_{11}^{(l)}} \frac{\partial z_{11}^{(l)}}{\partial a_{12}^{(l-1)}} \frac{\partial a_{12}^{(l-1)}}{\partial z_{12}^{(l-1)}} + \frac{\partial J}{\partial z_{12}^{(l)}} \frac{\partial z_{12}^{(l)}}{\partial a_{12}^{(l-1)}} \frac{\partial a_{12}^{(l-1)}}{\partial z_{12}^{(l-1)}} = \delta_{11}^{(l)} w_{12}^{(l)} \sigma'(z_{12}^{(l-1)}) + \delta_{12}^{(l)} w_{11}^{(l)} \sigma'(z_{12}^{(l-1)})$$

# 实例：残差规律

---


$$\begin{aligned} z_{11}^{(l)} &= \boxed{a_{11}^{(l-1)} w_{11}^{(l)}} + \boxed{a_{12}^{(l-1)} w_{12}^{(l)}} + \boxed{a_{21}^{(l-1)} w_{21}^{(l)}} + \boxed{a_{22}^{(l-1)} w_{22}^{(l)}} + b^{(l)} \\ z_{12}^{(l)} &= \boxed{a_{12}^{(l-1)} w_{11}^{(l)}} + \boxed{a_{13}^{(l-1)} w_{12}^{(l)}} + \boxed{a_{22}^{(l-1)} w_{21}^{(l)}} + \boxed{a_{23}^{(l-1)} w_{22}^{(l)}} + b^{(l)} \\ z_{21}^{(l)} &= \boxed{a_{21}^{(l-1)} w_{11}^{(l)}} + \boxed{a_{22}^{(l-1)} w_{12}^{(l)}} + \boxed{a_{31}^{(l-1)} w_{21}^{(l)}} + \boxed{a_{32}^{(l-1)} w_{22}^{(l)}} + b^{(l)} \\ z_{22}^{(l)} &= \boxed{a_{22}^{(l-1)} w_{11}^{(l)}} + \boxed{a_{23}^{(l-1)} w_{12}^{(l)}} + \boxed{a_{32}^{(l-1)} w_{21}^{(l)}} + \boxed{a_{33}^{(l-1)} w_{22}^{(l)}} + b^{(l)} \end{aligned}$$

一种颜色代表对前一层某个单元求残差时的相关项。

思考：前一层的残差与当前层的残差有什么关系？




# 前一层残差计算方式



1. 将卷积权重翻转 $180^\circ$ ；
2. 给当前层残差矩阵边界补0；
3. 使用翻转后的卷积核对pad后的残差做卷积。

# 前一层残差计算公式




$$\delta_{u,v}^{(l-1)} = \frac{\partial J}{\partial z_{u,v}^{(l-1)}} = \frac{\partial J}{\partial a_{u,v}^{(l-1)}} \frac{\partial a_{u,v}^{(l-1)}}{\partial z_{u,v}^{(l-1)}} = \sum_m \sum_n w_{m,n}^{(l)} \delta_{m+u-1,n+v-1}^l \sigma'(z_{u,v}^{(l-1)})$$

注意：此处 $u,v$ 表示 $l-1$ 层的行、列下标； $m,n$ 表示翻转后卷积核的行列下标。



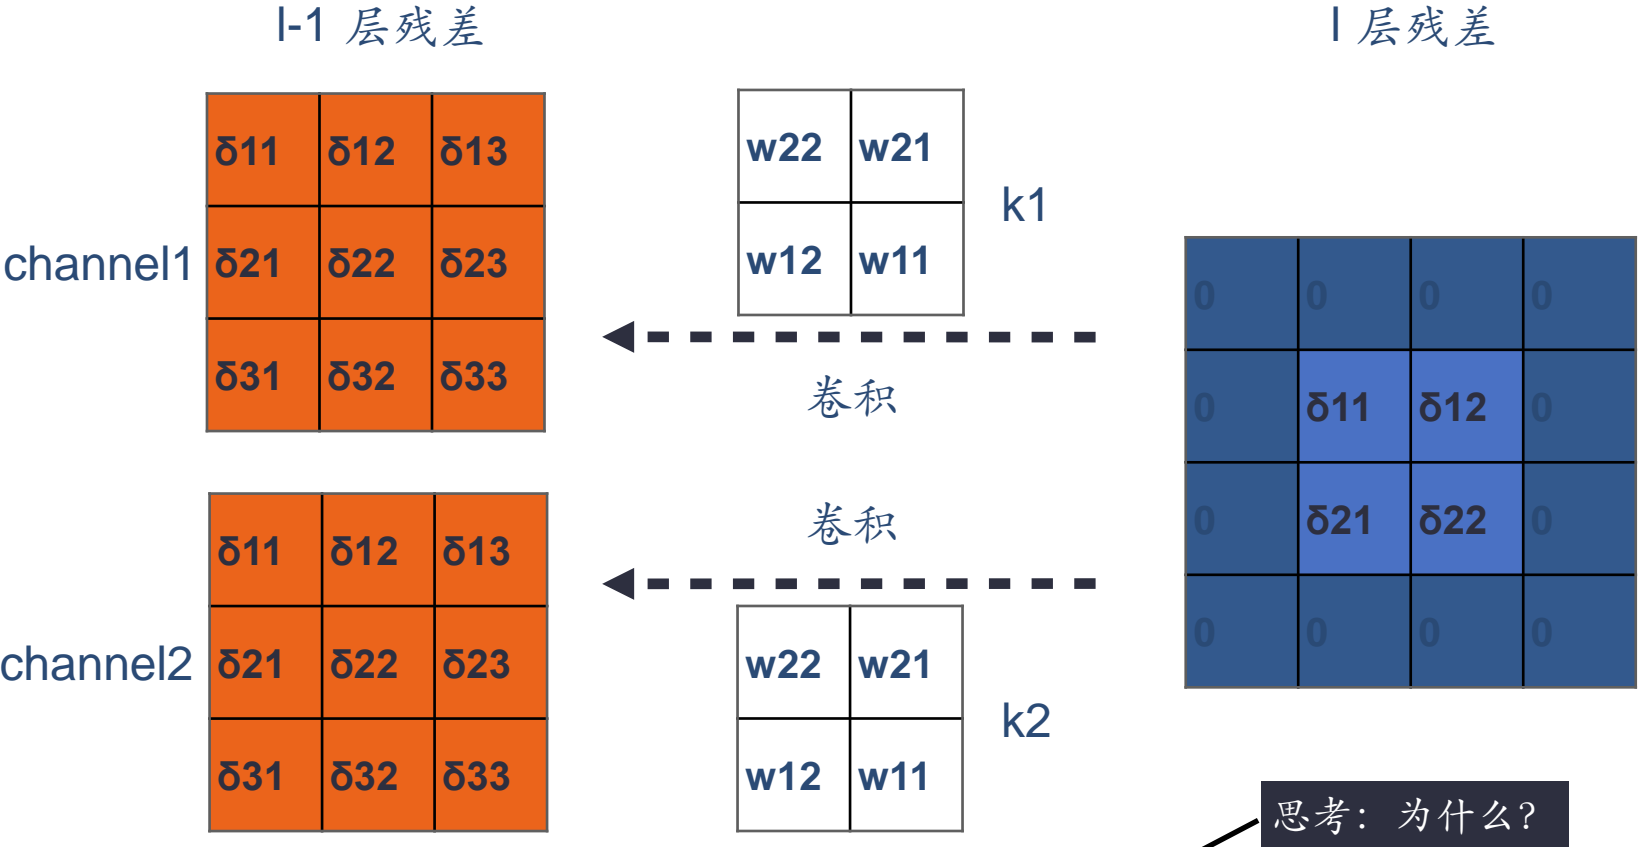
其它情况下卷积  
前一层的残差

# 当步长不为1时



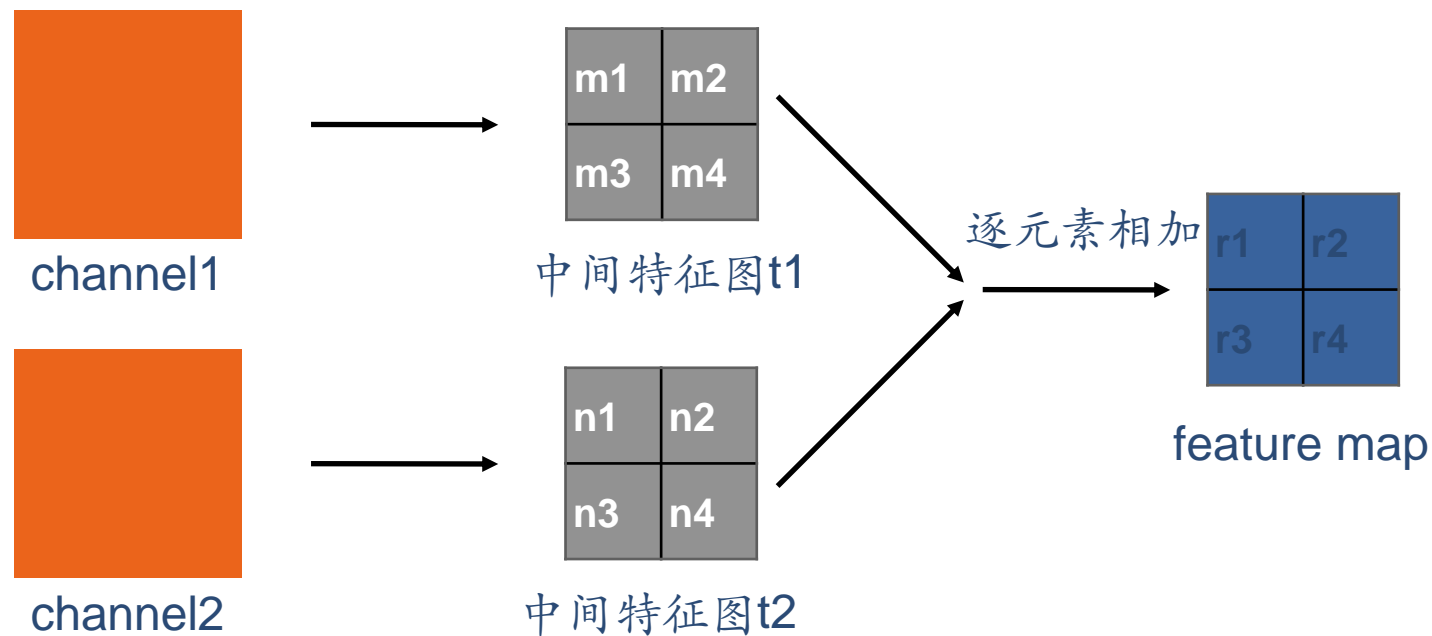
- 计算方法
- 1. 将卷积权重翻转 $180^\circ$ ；
  - 2. 使用0填充残差对应位置；
  - 3. 在残差外层填充0；
  - 4. 使用填充后的残差与翻转后的权重卷积。

# 当卷积输入通道不为1时



k1、k2分别表示每个通道的卷积参数，求残差时分别按照单个通道进行计算即可。

# 当卷积输入通道不为1时

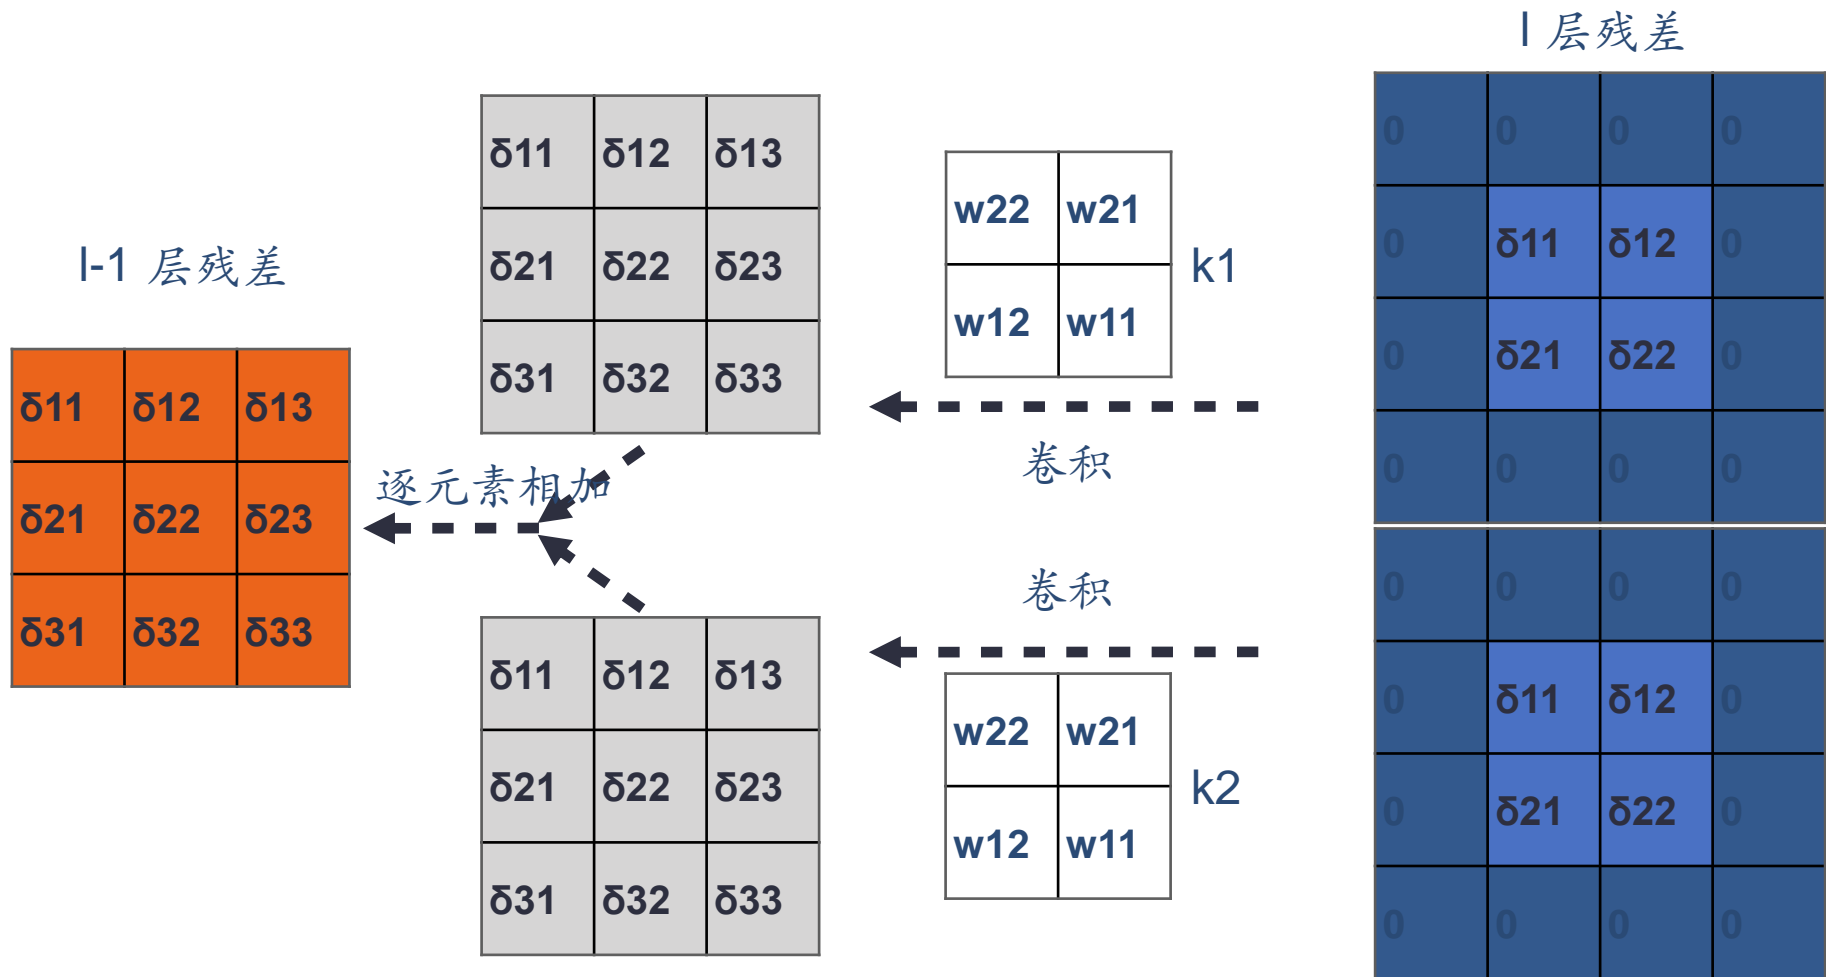


$$\frac{\partial(x_1 + x_2)}{\partial x_1} = \frac{\partial(x_1 + x_2)}{\partial x_2} = 1$$

$$\frac{\partial J}{\partial r} = \frac{\partial J}{\partial(t_1 + t_2)} = \frac{\partial J}{\partial r} \frac{\partial r}{\partial x_1} = \frac{\partial J}{\partial r} \frac{\partial r}{\partial x_2}$$

可以看到：中间特征图的残差等于特征图的残差。

# 当卷积核数量不为1时



$k_1$ 、 $k_2$ 分别表示两个卷积核。

# 当输入的边界有0填充时

---

1. 卷积输入的边界处理不影响反向传播过程。
2. 计算填充0的边界的残差是冗余的，没有意义的。



## 3.3 卷积核参数的 梯度

# 卷积核参数

---


卷积中参数：

1. 卷积中的参数都来自于卷积核。
2. 卷积核的参数参与了当前层输入的计算。



# 实例

# 实例



$$z_{11}^{(l)} = a_{11}^{(l-1)}w_{11}^{(l)} + a_{12}^{(l-1)}w_{12}^{(l)} + a_{21}^{(l-1)}w_{21}^{(l)} + a_{22}^{(l-1)}w_{22}^{(l)} + b^{(l)}$$

$$z_{12}^{(l)} = a_{12}^{(l-1)}w_{11}^{(l)} + a_{13}^{(l-1)}w_{12}^{(l)} + a_{22}^{(l-1)}w_{21}^{(l)} + a_{23}^{(l-1)}w_{22}^{(l)} + b^{(l)}$$

$$z_{21}^{(l)} = a_{21}^{(l-1)}w_{11}^{(l)} + a_{22}^{(l-1)}w_{12}^{(l)} + a_{31}^{(l-1)}w_{21}^{(l)} + a_{32}^{(l-1)}w_{22}^{(l)} + b^{(l)}$$

$$z_{22}^{(l)} = a_{22}^{(l-1)}w_{11}^{(l)} + a_{23}^{(l-1)}w_{12}^{(l)} + a_{32}^{(l-1)}w_{21}^{(l)} + a_{33}^{(l-1)}w_{22}^{(l)} + b^{(l)}$$

# 例子—求权重的梯度

$$z_{11}^{(l)} = a_{11}^{(l-1)} w_{11}^{(l)} + a_{12}^{(l-1)} w_{12}^{(l)} + a_{21}^{(l-1)} w_{21}^{(l)} + a_{22}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{12}^{(l)} = a_{12}^{(l-1)} w_{11}^{(l)} + a_{13}^{(l-1)} w_{12}^{(l)} + a_{22}^{(l-1)} w_{21}^{(l)} + a_{23}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{21}^{(l)} = a_{21}^{(l-1)} w_{11}^{(l)} + a_{22}^{(l-1)} w_{12}^{(l)} + a_{31}^{(l-1)} w_{21}^{(l)} + a_{32}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{22}^{(l)} = a_{22}^{(l-1)} w_{11}^{(l)} + a_{23}^{(l-1)} w_{12}^{(l)} + a_{32}^{(l-1)} w_{21}^{(l)} + a_{33}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$\begin{aligned} \frac{\partial J}{\partial w_{11}^{(l)}} &= \frac{\partial J}{\partial z_{11}^{(l)}} \frac{\partial z_{11}^{(l)}}{\partial w_{11}^{(l)}} + \frac{\partial J}{\partial z_{12}^{(l)}} \frac{\partial z_{12}^{(l)}}{\partial w_{11}^{(l)}} + \frac{\partial J}{\partial z_{21}^{(l)}} \frac{\partial z_{21}^{(l)}}{\partial w_{11}^{(l)}} + \frac{\partial J}{\partial z_{22}^{(l)}} \frac{\partial z_{22}^{(l)}}{\partial w_{11}^{(l)}} \\ &= \delta_{11}^{(l)} a_{11}^{(l-1)} + \delta_{12}^{(l)} a_{12}^{(l-1)} + \delta_{21}^{(l)} a_{21}^{(l-1)} + \delta_{22}^{(l)} a_{22}^{(l-1)} \end{aligned}$$

|               |               |
|---------------|---------------|
| $\delta_{11}$ | $\delta_{12}$ |
| $\delta_{21}$ | $\delta_{22}$ |

残差

|          |          |          |
|----------|----------|----------|
| $a_{11}$ | $a_{12}$ | $a_{13}$ |
| $a_{21}$ | $a_{22}$ | $a_{23}$ |
| $a_{31}$ | $a_{32}$ | $a_{33}$ |

输入（前一层输出）

# 例子—求权重的梯度

$$z_{11}^{(l)} = a_{11}^{(l-1)} w_{11}^{(l)} + a_{12}^{(l-1)} w_{12}^{(l)} + a_{21}^{(l-1)} w_{21}^{(l)} + a_{22}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{12}^{(l)} = a_{12}^{(l-1)} w_{11}^{(l)} + a_{13}^{(l-1)} w_{12}^{(l)} + a_{22}^{(l-1)} w_{21}^{(l)} + a_{23}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{21}^{(l)} = a_{21}^{(l-1)} w_{11}^{(l)} + a_{22}^{(l-1)} w_{12}^{(l)} + a_{31}^{(l-1)} w_{21}^{(l)} + a_{32}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{22}^{(l)} = a_{22}^{(l-1)} w_{11}^{(l)} + a_{23}^{(l-1)} w_{12}^{(l)} + a_{32}^{(l-1)} w_{21}^{(l)} + a_{33}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$\begin{aligned} \frac{\partial J}{\partial w_{12}^{(l)}} &= \frac{\partial J}{\partial z_{11}^{(l)}} \frac{\partial z_{11}^{(l)}}{\partial w_{12}^{(l)}} + \frac{\partial J}{\partial z_{12}^{(l)}} \frac{\partial z_{12}^{(l)}}{\partial w_{12}^{(l)}} + \frac{\partial J}{\partial z_{21}^{(l)}} \frac{\partial z_{21}^{(l)}}{\partial w_{12}^{(l)}} + \frac{\partial J}{\partial z_{22}^{(l)}} \frac{\partial z_{22}^{(l)}}{\partial w_{12}^{(l)}} \\ &= \delta_{11}^{(l)} a_{12}^{(l-1)} + \delta_{12}^{(l)} a_{13}^{(l-1)} + \delta_{21}^{(l)} a_{22}^{(l-1)} + \delta_{22}^{(l)} a_{23}^{(l-1)} \end{aligned}$$

以此类推可以得到所有J对w的梯度。

|               |               |
|---------------|---------------|
| $\delta_{11}$ | $\delta_{12}$ |
| $\delta_{21}$ | $\delta_{22}$ |

残差

|     |     |     |
|-----|-----|-----|
| a11 | a12 | a13 |
| a21 | a22 | a23 |
| a31 | a32 | a33 |

输入（前一层输出）

# 例子—求偏置值的梯度

$$z_{11}^{(l)} = a_{11}^{(l-1)} w_{11}^{(l)} + a_{12}^{(l-1)} w_{12}^{(l)} + a_{21}^{(l-1)} w_{21}^{(l)} + a_{22}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{12}^{(l)} = a_{12}^{(l-1)} w_{11}^{(l)} + a_{13}^{(l-1)} w_{12}^{(l)} + a_{22}^{(l-1)} w_{21}^{(l)} + a_{23}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{21}^{(l)} = a_{21}^{(l-1)} w_{11}^{(l)} + a_{22}^{(l-1)} w_{12}^{(l)} + a_{31}^{(l-1)} w_{21}^{(l)} + a_{32}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

$$z_{22}^{(l)} = a_{22}^{(l-1)} w_{11}^{(l)} + a_{23}^{(l-1)} w_{12}^{(l)} + a_{32}^{(l-1)} w_{21}^{(l)} + a_{33}^{(l-1)} w_{22}^{(l)} + b^{(l)}$$

|               |               |
|---------------|---------------|
| $\delta_{11}$ | $\delta_{12}$ |
| $\delta_{21}$ | $\delta_{22}$ |

残差

$$\begin{aligned} \frac{\partial J}{\partial b^{(l)}} &= \frac{\partial J}{\partial z_{11}^{(l)}} \frac{\partial z_{11}^{(l)}}{\partial b^{(l)}} + \frac{\partial J}{\partial z_{12}^{(l)}} \frac{\partial z_{12}^{(l)}}{\partial b^{(l)}} + \frac{\partial J}{\partial z_{21}^{(l)}} \frac{\partial z_{21}^{(l)}}{\partial b^{(l)}} + \frac{\partial J}{\partial z_{22}^{(l)}} \frac{\partial z_{22}^{(l)}}{\partial b^{(l)}} \\ &= \delta_{11}^{(l)} + \delta_{12}^{(l)} + \delta_{21}^{(l)} + \delta_{22}^{(l)} \end{aligned}$$

# 卷积核的梯度

---

权重的梯度: 
$$\frac{\partial J}{\partial w_{p,q}^{(l)}} = \sum_u \sum_v \delta_{u,v}^{(l)} a_{u+p-1,v+q-1}^{(l-1)}$$

将当前层的残差与前一层的输出做卷积。

偏置值的梯度: 
$$\frac{\partial J}{\partial b^{(l)}} = \sum_u \sum_v \delta_{u,v}^{(l)}$$

将当前层当前特征图的残差求和。



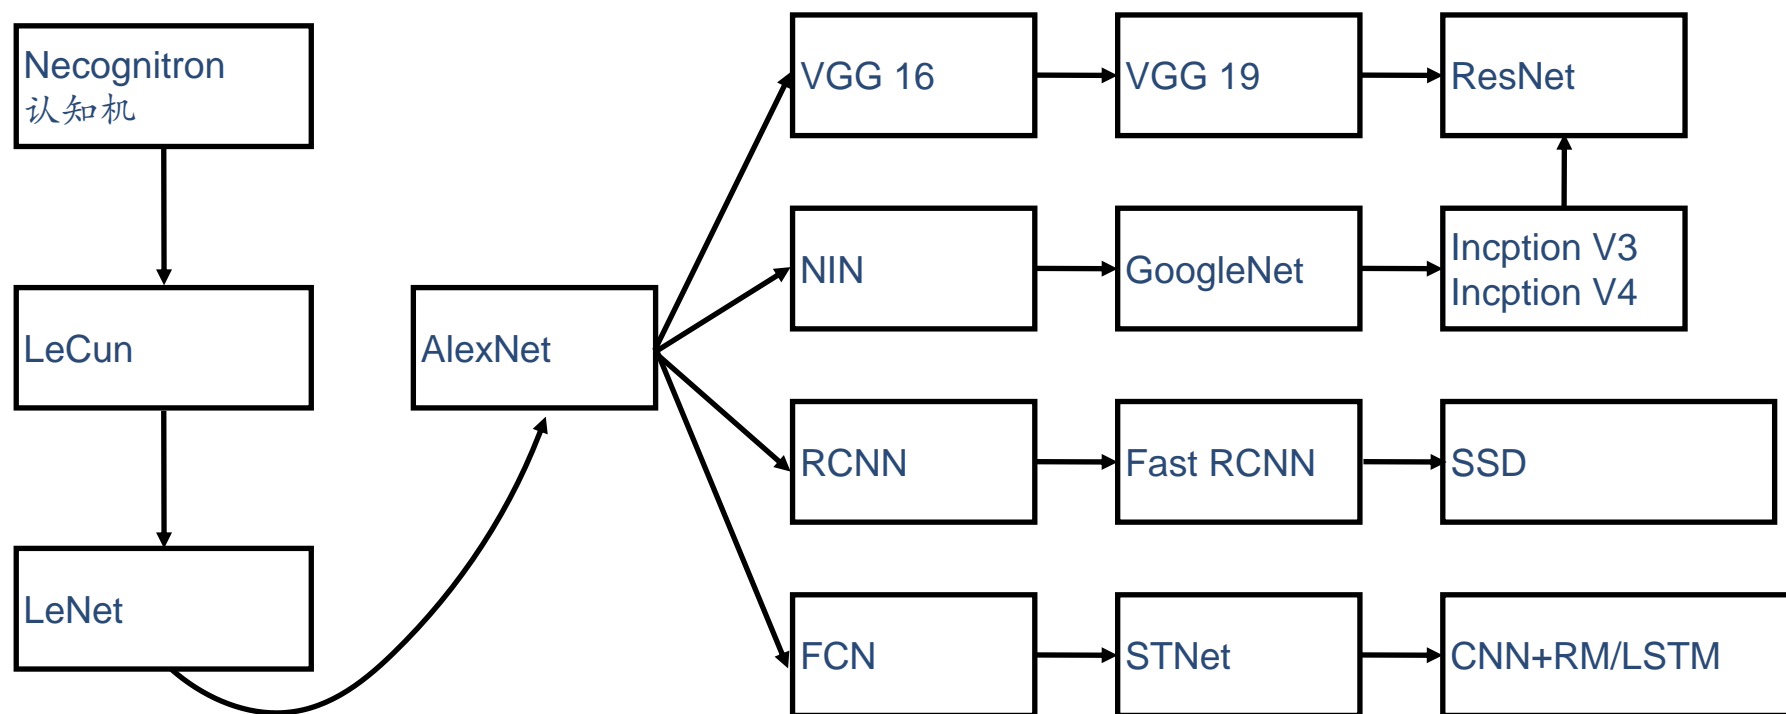
# CNN中的参数

---


- ▶ 卷积层的参数包括卷积核参数与偏置值。偏置值数量等于生成的特征图的激活值数量（同一个特征图中的偏置值相同）。
- ▶ 池化层通常没有连接权重、偏置值和激活函数。
- ▶ 全连接层的参数。

## 4. 卷积神经网络 中的重要模型

# 卷积神经网络结构演化史



# AlexNet



2012, Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton

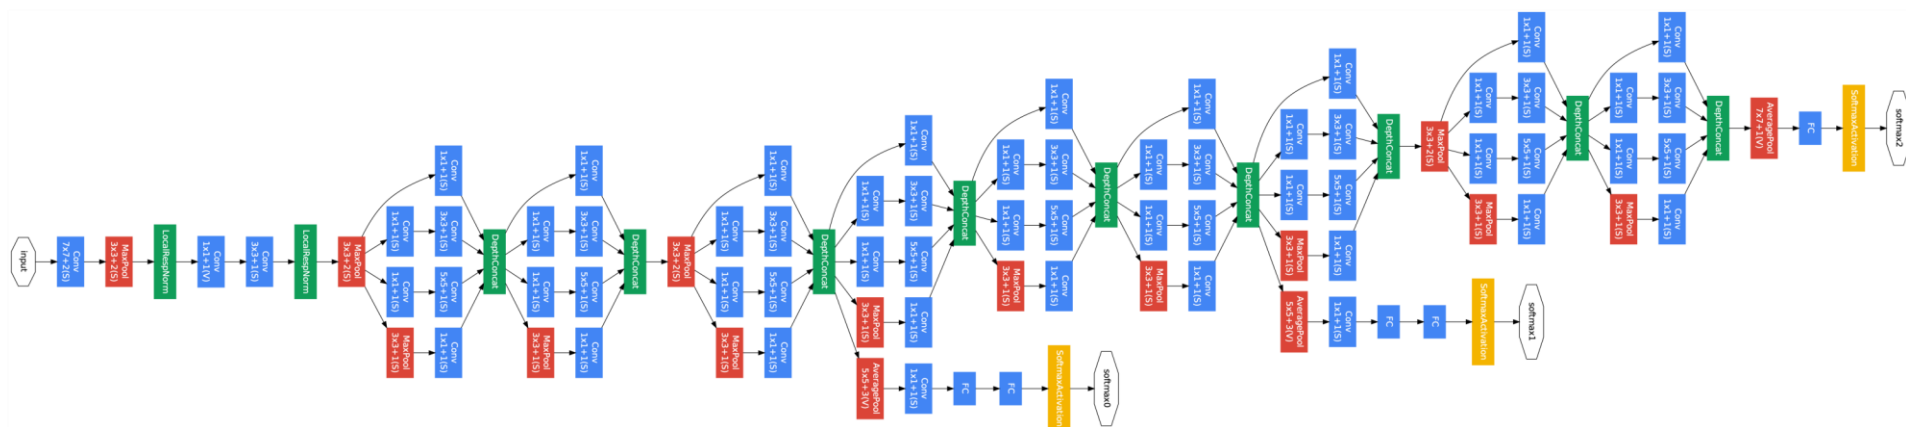
特点:

使用ReLU激活函数

使用Dropout技术缓解了过拟合

使用了重叠最大池化

# GoogLeNet



2014, Christian Szegedy, Wei Liu, Yangqing Jia. et al

特点： 使用Inception结构

# ResNet

| layer name | output size | 18-layer  | 34-layer  | 50-layer   | 101-layer   | 152-layer   |
|------------|-------------|---|---|--|---|---|
| conv1      | 112×112     | 7×7, 64, stride 2   |   |  |   |   |
| conv2_x    | 56×56       | 3×3 max pool, stride 2  |   |  |   |   |
|            |             | $\begin{bmatrix} 3\times 3, 64 \\ 3\times 3, 64 \end{bmatrix} \times 2$   | $\begin{bmatrix} 3\times 3, 64 \\ 3\times 3, 64 \end{bmatrix} \times 3$   | $\begin{bmatrix} 1\times 1, 64 \\ 3\times 3, 64 \\ 1\times 1, 256 \end{bmatrix} \times 3$    | $\begin{bmatrix} 1\times 1, 64 \\ 3\times 3, 64 \\ 1\times 1, 256 \end{bmatrix} \times 3$     | $\begin{bmatrix} 1\times 1, 64 \\ 3\times 3, 64 \\ 1\times 1, 256 \end{bmatrix} \times 3$     |
| conv3_x    | 28×28       | $\begin{bmatrix} 3\times 3, 128 \\ 3\times 3, 128 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3\times 3, 128 \\ 3\times 3, 128 \end{bmatrix} \times 4$ | $\begin{bmatrix} 1\times 1, 128 \\ 3\times 3, 128 \\ 1\times 1, 512 \end{bmatrix} \times 4$  | $\begin{bmatrix} 1\times 1, 128 \\ 3\times 3, 128 \\ 1\times 1, 512 \end{bmatrix} \times 4$   | $\begin{bmatrix} 1\times 1, 128 \\ 3\times 3, 128 \\ 1\times 1, 512 \end{bmatrix} \times 8$   |
| conv4_x    | 14×14       | $\begin{bmatrix} 3\times 3, 256 \\ 3\times 3, 256 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3\times 3, 256 \\ 3\times 3, 256 \end{bmatrix} \times 6$ | $\begin{bmatrix} 1\times 1, 256 \\ 3\times 3, 256 \\ 1\times 1, 1024 \end{bmatrix} \times 6$ | $\begin{bmatrix} 1\times 1, 256 \\ 3\times 3, 256 \\ 1\times 1, 1024 \end{bmatrix} \times 23$ | $\begin{bmatrix} 1\times 1, 256 \\ 3\times 3, 256 \\ 1\times 1, 1024 \end{bmatrix} \times 36$ |
| conv5_x    | 7×7         | $\begin{bmatrix} 3\times 3, 512 \\ 3\times 3, 512 \end{bmatrix} \times 2$ | $\begin{bmatrix} 3\times 3, 512 \\ 3\times 3, 512 \end{bmatrix} \times 3$ | $\begin{bmatrix} 1\times 1, 512 \\ 3\times 3, 512 \\ 1\times 1, 2048 \end{bmatrix} \times 3$ | $\begin{bmatrix} 1\times 1, 512 \\ 3\times 3, 512 \\ 1\times 1, 2048 \end{bmatrix} \times 3$  | $\begin{bmatrix} 1\times 1, 512 \\ 3\times 3, 512 \\ 1\times 1, 2048 \end{bmatrix} \times 3$  |
|            | 1×1         | average pool, 1000-d fc, softmax  |   |  |   |   |
| FLOPs      |             | $1.8 \times 10^9$   | $3.6 \times 10^9$   | $3.8 \times 10^9$  | $7.6 \times 10^9$   | $11.3 \times 10^9$  |

2015, Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun

特点：使用Deeper Bottleneck Architectures (DBA) 结构

# 小结

---

- ▶ 局部连接与权值共享降低了连接数量与参数数量。
- ▶ 卷积层反向传播残差到前一层的计算方法是：翻转卷积核与补0的当前层残差做卷积。
- ▶ 卷积层连接权重的梯度计算方法是：使用当前层的残差与前一层的输出做卷积。
- ▶ 卷积层偏置值的梯度计算方法是：将当前某个特征图的残差累加作为此特征图偏置值的残差。
- ▶ 卷积神经网络中的重要模型。



THANKS